



LAPORAN TEKNIS KOMPREHENSIF

CEAMIS

Financial Health Analytics

End-to-End Data Science Project Report

Problem Discovery → Data Collection → Data Wrangling → Feature Engineering → EDA →
Modeling → Kesimpulan & Rekomendasi

Proyek	CEAMIS — Comprehensive Earnings, Asset Management & Investment System
Notebook	Financial_Health_Analytics.ipynb model3_risk_profile_...cleaned_v2.ipynb
Dataset	105.000 baris transaksi (multi-source Kaggle) + 20.000 baris onboarding data
Model	Model 1: Financial Health Score Model 2: Spending Cluster Model 3: Risk Profile
Regulasi	OJK SEOJK No. 13/SEOJK.07/2014, Bank Indonesia Surat Edaran DTI, NFWBS PUF 2016
Tanggal	05 June 2026
Tim	CEAMIS Data Science Team

0 DAFTAR ISI

1.	Problem Discovery & Latar Belakang	3
2.	Tujuan Bisnis & Pertanyaan Penelitian	4
3.	Sumber Data & Akuisisi	5
4.	Data Understanding & Asesmen Kualitas	6
5.	Data Wrangling & Cleaning	7
6.	Feature Engineering	9
7.	Exploratory Data Analysis (EDA)	12
8.	Explanatory Analysis — 9 Pertanyaan Bisnis	14
9.	Model 1: Financial Health Score (Weighted Scoring)	16
10.	Model 2: Spending Cluster (KMeans)	19
11.	Model 3: Risk Profile Classification (CEAMIS Score)	21
12.	Validasi & Quality Assurance	25
13.	Kesimpulan	26
14.	Rekomendasi & Action Items	27
15.	Referensi	29

1.1 Konteks Permasalahan

Kesehatan finansial masyarakat Indonesia merupakan isu kritis yang berdampak luas terhadap stabilitas ekonomi nasional. Data Otoritas Jasa Keuangan (OJK) menunjukkan bahwa indeks literasi keuangan Indonesia hanya mencapai 49,68% pada tahun 2022 — artinya lebih dari separuh populasi belum memiliki pemahaman finansial yang memadai untuk mengelola keuangan pribadinya secara optimal.

Data OJK 2022

Indeks literasi keuangan Indonesia: 49,68% | Indeks inklusi keuangan: 85,10%
— Kesenjangan antara akses layanan keuangan dan kemampuan mengelolanya mencerminkan urgensi sistem edukasi finansial berbasis data.

Rendahnya Saving Rate	Saving rate rata-rata masyarakat Indonesia berada di bawah 20%, jauh dari target minimal yang direkomendasikan untuk membangun ketahanan finansial (Bank Indonesia).
DTI Melebihi Batas Aman	Rasio Debt-to-Income (DTI) banyak kelompok pengeluaran melebihi ambang 30% yang ditetapkan OJK sebagai batas risiko (SEOJK No. 13/SEOJK.07/2014).
Pengeluaran Impulsif	Pola belanja tidak terencana — terutama menjelang akhir bulan — menguras cashflow dan menghambat akumulasi tabungan.
Investasi Rendah	Partisipasi investasi kalangan muda dan berpenghasilan menengah masih sangat rendah karena kurangnya pemahaman produk keuangan.
Tidak Ada Sistem Scoring	Belum tersedia sistem terstandarisasi yang mampu mengukur kesehatan finansial individu secara komprehensif dan real-time berbasis data transaksi.

1.2 Solusi yang Dibangun

CEAMIS (Comprehensive Earnings, Asset Management & Investment System) dibangun sebagai respons terhadap permasalahan tersebut. Sistem ini mengintegrasikan tiga model machine learning komplementer yang bekerja dalam satu pipeline end-to-end:

Model	Nama	Pendekatan	Output Utama
Model 1	Financial Health Score	Weighted Scoring Rule-based + Normalisasi	Skor 0–100, Label 5 tier
Model 2	Spending Cluster	Unsupervised Learning (KMeans)	4 profil pola belanja pengguna
Model 3	Risk Profile Classification	CEAMIS Score + Override Rules	Konservatif / Moderat / Agresif

2.1 Tujuan Bisnis

ID	Tujuan	Metode
BG-1	Mengukur kesehatan finansial pengguna secara kuantitatif	Weighted Scoring Formula (Model 1)
BG-2	Mengelompokkan pola belanja pengguna	KMeans Clustering (Model 2)
BG-3	Mengidentifikasi faktor risiko finansial	Explanatory & Correlation Analysis
BG-4	Mengklasifikasikan profil risiko investasi	CEAMIS Score + Rule-based (Model 3)
BG-5	Memberikan rekomendasi berbasis data	Rule-based + ML Insight
BG-6	Menyediakan dashboard interaktif	Streamlit Multi-page Dashboard

2.2 Sembilan Pertanyaan Bisnis

- BQ1 — Seberapa sehat kondisi finansial pengguna setiap bulan, dan faktor apa yang paling memengaruhi naik-turunnya health score?
- BQ2 — Segmen pengguna mana yang paling berisiko mengalami kondisi finansial kritis berdasarkan profil usia, pekerjaan, literasi, dan tanggungan?
- BQ3 — Pola pengeluaran apa yang paling sering menyebabkan cashflow negatif?
- BQ4 — Apakah pengguna lebih banyak menghabiskan uang pada needs, wants, saving, investment, atau debt?
- BQ5 — Apakah transaksi impulsif berkorelasi negatif dengan saving rate dan health score?
- BQ6 — Apakah ada pola pengeluaran yang meningkat signifikan menjelang akhir bulan?
- BQ7 — Kategori pengeluaran apa yang menjadi "bocor halus" (invisible drain)?
- BQ8 — Rekomendasi apa yang paling efektif untuk meningkatkan saving rate dan budget adherence?
- BQ9 — Kondisi seperti apa yang harus memicu warning message dan recovery plan otomatis?

3.1 Dataset Primer — Kaggle API

Data transaksi diperoleh dari tiga dataset publik Kaggle yang dikombinasikan untuk membentuk dataset komprehensif dengan cakupan pola perilaku keuangan yang beragam. Pengambilan data dilakukan melalui Kaggle API dengan autentikasi token (kaggle.json), yang merupakan praktik standar dalam pipeline data engineering modern.

Dataset	Slug Kaggle	Kolom Kunci	Tipe Transaksi	Jumlah Baris
Personal Finance Tracker	bukolafatunde/personal-finance	Date, Amount, Category, Account	Income & Expense	~5.000
Bank Transaction Data 2024	apoorwatsky/bank-transaction-data	Date, Withdrawal, Deposit, Balance	Debit & Credit	~10.000
Credit Card Transactions	priyamchoksi/credit-card-transactions-dataset	trans_date, amt, category, cc_num	Expense	~100.000+
Financial Onboarding (Backbone)	data.csv (India Dataset)	Income, Age, Occupation, Dependents, Expenses	Profil Pengguna	~20.000

3.2 Dataset Referensi Regulasi — Web Scraping & Fallback

Untuk memperkuat validitas konteks Indonesia, data referensi regulasi dikumpulkan dari tiga institusi resmi melalui web scraping dengan library requests dan BeautifulSoup4. Apabila scraping gagal (timeout/struktur HTML berubah), sistem menggunakan data fallback hardcoded yang mencerminkan nilai terakhir yang valid.

Institusi	Data	Metode	Penggunaan dalam Model
BPS (Badan Pusat Statistik)	Pengeluaran per kapita bulanan 2023 per kategori	Web scraping + fallback	Benchmarking rasio needs vs wants
OJK (Otoritas Jasa Keuangan)	Indeks literasi & inklusi keuangan 2013–2022	Fallback hardcoded	Normalisasi financial_literacy_score; batas DTI 30%
Bank Indonesia	Data inflasi tahunan 2019–2023	Web scraping + fallback	Konteks makroekonomi & penyesuaian nilai riil
NFWBS PUF 2016 (CFPB)	National Financial Well-Being Survey — perilaku tabungan, kontrol diri, horizon perencanaan	CSV lokal (sep=";")	Join heuristik untuk kolom SAVEHABIT, SELFCONTROL_1, SCFHORIZON, FINGOALS

**Catatan Mata
Uang**

Dataset backbone berasal dari India (nilai dalam INR). Semua kolom moneter dikonversi ke IDR menggunakan kurs tetap: 1 USD = Rp 16.000 | 1 USD = 83 INR → 1 INR ≈ Rp 192,77. Pendekatan ini memastikan komparabilitas nilai absolut dalam konteks Indonesia.

4.1 Eksplorasi Awal (Basic EDA)

Tahap data understanding dimulai dengan fungsi `explore_dataset()` yang mengeksekusi `df.head()`, `df.info()`, dan `df.describe(include="all")` untuk setiap dataset. Tujuannya adalah memahami struktur kolom, tipe data, rentang nilai, dan distribusi awal sebelum proses cleaning dilakukan.

Alasan Ilmiah

Exploratory inspection sebelum cleaning merupakan best practice dalam data science workflow (Wickham & Grolemund, 2017 — "R for Data Science"). Tanpa pemahaman mendalam tentang struktur data, cleaning yang dilakukan berpotensi menghapus informasi yang berharga atau memperkenalkan bias sistematis.

4.2 Analisis Missing Values

Setiap kolom dievaluasi dengan `df.isnull().sum()` dan dihitung persentase missing-nya. Strategi penanganan ditentukan berdasarkan persentase missing: kolom dengan >50% missing dihapus (drop), missing 20–50% diisi dengan median, dan missing <20% diisi dengan mean. Untuk variabel kategorikal, digunakan mode imputation.

Referensi: Little & Rubin (2002) "Statistical Analysis with Missing Data" — threshold 50% untuk drop kolom adalah konvensi yang diterima secara luas dalam missing data analysis.

4.3 Deteksi Duplikat & Outlier Awal

Duplikat dideteksi dengan `df.duplicated().sum()`. Untuk outlier, digunakan metode IQR (Interquartile Range): nilai di luar rentang $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ dianggap outlier. Deteksi ini bersifat informatif — keputusan penanganan outlier dilakukan di tahap wrangling.

Metode	Formula	Interpretasi
Lower Fence	$Q1 - 1.5 \times IQR$	Nilai di bawah ini dianggap outlier bawah
Upper Fence	$Q3 + 1.5 \times IQR$	Nilai di atas ini dianggap outlier atas
IQR	$Q3 - Q1$	Rentang interkuartil sebagai ukuran dispersi robust

5 DATA WRANGLING & CLEANING

5.1 Standardisasi Format Multi-Dataset

Ketiga dataset Kaggle memiliki skema kolom yang berbeda. Langkah standardisasi dilakukan melalui fungsi `safe_read_csv()` dengan fallback encoding (UTF-8 → Latin-1 → CP1252), kemudian setiap dataset diproyeksikan ke schema seragam: `[user_id, date, amount, category, transaction_type, source]`.

Dataset Asal	Kolom Asli	Kolom Standar	Transformasi
Personal Finance	Date, Amount, Transaction Type, Category	date, amount, transaction_type, category	lowercase, credit→income, debit→expense
Bank Transaction	DATE, WITHDRAWAL AMT, DEPOSIT AMT	date, amount, transaction_type	Withdrawal→expense, Deposit→income, row explode
Credit Card	trans_date_trans_time, amt, category, cc_num	date, amount, category, user_id	Downsample 10.000, cc_num→user_id mapping
Onboarding (Model 3)	Income, Rent, Groceries, Age, Occupation, ...	penghasilan_bulanan, pengeluaran_tetap, ...	INR→IDR konversi, derive kolom baru

5.2 Penanganan Missing Values

Fungsi `handle_missing()` menerapkan strategi adaptive imputation: drop (>50% missing), mode imputation (kategorikal), median imputation (numerik dengan >20% missing), dan mean imputation (numerik dengan ≤20% missing). Baris dengan `amount ≤ 0` dihapus karena tidak merepresentasikan transaksi yang valid.

5.3 Outlier Handling — IQR Capping (Winsorization)

Outlier tidak dihapus, melainkan di-cap menggunakan metode winsorization pada persentil [1%, 99%] melalui fungsi `cap_outliers_iqr()`. Pendekatan ini mempertahankan semua observasi sembari mereduksi pengaruh nilai ekstrem terhadap distribusi dan model.

Alasan Memilih Winsorization

Menghapus outlier pada data keuangan berisiko menghilangkan kasus-kasus edge yang justru paling relevan (misalnya pengguna dengan utang sangat tinggi atau income sangat rendah). Winsorization mempertahankan informasi struktural sambil mengurangi distorsi statistik (Ghosh & Vogt, 2012 — Outliers: An Evaluation of Methodologies).

5.4 Category Mapping — Spending Group

Ratusan kategori transaksi dari berbagai sumber dipetakan ke 6 kelompok standar melalui `CATEGORY_MAP` dictionary dengan 80+ entry. Pemetaan menggunakan exact match terlebih dahulu, kemudian substring match untuk kategori yang tidak terdaftar.

Spending Group	Contoh Kategori Asli	Representasi
Needs	groceries, utilities, rent, mortgage, health_fitness, transport	Kebutuhan primer & wajib
Wants	shopping, restaurants, entertainment, travel, clothing, coffee shops	Pengeluaran diskresioner
Saving	transfer, savings, tabungan, deposit, bank_transfer	Alokasi tabungan aktif
Investment	investment, stocks, crypto, saham, investasi	Instrumen investasi
Debt	credit card payment, loan, cicilan, kredit, pinjaman	Pembayaran kewajiban utang
Income	paycheck, salary, income, bonus, refund	Penerimaan pendapatan

5.5 Agregasi ke Level User-Monthly

Data transaksi level individual diagregasi ke level user × month menggunakan groupby. Untuk setiap kombinasi (user_id, year_month) dihitung: total expense, total income, jumlah transaksi, total per spending group, dan rasio pengeluaran akhir bulan (hari 25–31). Income yang tidak tersedia diestimasi dengan factor 1.1–1.7× dari expense.

6.1 Core Financial Ratios

Dari data transaksi yang telah diagregasi, diturunkan rasio-rasio keuangan inti yang menjadi building blocks seluruh model. Semua rasio dinormalisasi ke rentang [0, 1] menggunakan `.clip(0, 1)` untuk menghindari nilai ekstrem.

Fitur	Formula	Interpretasi	Referensi
saving_rate	$(\text{income} - \text{expense}) / \text{income}$	Proporsi pendapatan yang ditabung	OJK: target minimum 20%
needs_ratio	$\text{total_needs} / \text{expense}$	Proporsi pengeluaran untuk kebutuhan primer	Ramsey 50/30/20 Rule
wants_ratio	$\text{total_wants} / \text{expense}$	Proporsi pengeluaran untuk keinginan	Ramsey 50/30/20 Rule
investment_rate	$\text{total_investment} / \text{income}$	Proporsi pendapatan untuk investasi	OJK rekomendasi $\geq 10\%$
debt_ratio	$\text{total_debt} / \text{income}$	Rasio pembayaran utang terhadap pendapatan	OJK DTI limit 30%
dti_score	$\text{debt_ratio} \times 100$	DTI dalam skala persentase (0–100)	SEOJK 13/2014
impulsive_ratio	$\text{total_wants} / \text{median_wants}, \text{clip}[0,1]$	Ukuran relatif pengeluaran impulsif	Behavioral Finance
budget_adherence	$1 - \text{saving_rate} - 0.20 / 0.20, \text{clip}[0,1]$	Kedekatan saving_rate dengan target 20%	Personal Finance Target
monthly_balance	$\text{income} - \text{expense}$	Saldo bersih bulanan (cash position)	Cash Flow Analysis
eom_spending_ratio	$\text{Pengeluaran hari 25–31} / \text{total expense}$	Proporsi belanja akhir bulan	Behavioral Finance
financial_literacy_score	$\text{Normal}(0.4968, 0.15) \text{ clip}[0,1]$	Skor literasi keuangan berdasarkan OJK 2022	OJK Survei 2022

6.2 Feature Engineering — Model 3 (Onboarding Profile)

Untuk Model 3, feature engineering lebih kompleks karena memerlukan derivasi dari data onboarding pengguna yang bersifat profil (bukan transaksi). Berikut kolom-kolom utama yang diturunkan beserta logika bisnis yang mendasarinya.

Fitur	Logika Derivasi	Tipe Data
penghasilan_bulanan	Income_IDR (konversi langsung dari INR)	Float (IDR)
pengeluaran_tetap	Rent + Loan + Insurance + Utilities + Education (semua IDR)	Float (IDR)

pengeluaran_variabel	Groceries + Transport + Eating_Out + Entertainment + Healthcare + Misc (IDR)	Float (IDR)
diti_ratio	Loan_Repayment_IDR / penghasilan_bulanan, clip[0,1]	Float [0,1]
saving_rate	Desired_Savings_IDR / penghasilan_bulanan, clip[0,1]	Float [0,1]
jumlah_tabungan_bulan	(Desired_Savings×6) / total_pengeluaran, cap 36 bulan	Float
punya_investasi	Rule-based: disposable_ratio > 0.20 AND saving_pct > 15	Binary [0,1]
jenis_investasi	Rule-based: occupation × income_quartile → produk investasi	Kategorikal
tujuan_keuangan	Rule-based: age × occupation × income_quartile → tujuan	Ordinal (4 level)
toleransi_rugi	Rule-based: disposable + DTI + age + saving_rate → risk appetite	Ordinal (3 level)
SAVEHABIT, SELFCONTROL_1, SCFHORIZON, FINGOALS	Stochastic join dari NFWBS PUF 2016 berdasarkan agecat × income_quartile	Integer (scale varies)

NFWBS Join Methodology

Nilai perilaku keuangan (SAVEHABIT, SELFCONTROL, dll.) di-assign menggunakan distribusi empiris dari NFWBS PUF 2016 (Consumer Financial Protection Bureau, 2016). Setiap pengguna di-petakan ke sel agecat × income_quartile, lalu di-sample dari distribusi Normal yang dikalibrasi ke statistik (mean, std) survei nyata per sel. Pendekatan ini menghasilkan profil perilaku yang lebih realistis dibanding assignment acak murni.

6.3 Normalisasi Fitur — MinMaxScaler

Semua fitur numerik yang digunakan dalam model dinormalisasi ke rentang [0, 1] menggunakan MinMaxScaler dari scikit-learn. Normalisasi penting untuk: (1) menghindari dominasi fitur dengan skala besar (seperti income dalam jutaan Rupiah) terhadap fitur bertipe rasio [0,1], dan (2) memastikan bobot dalam formula Health Score dapat diinterpretasikan secara linear.

7.1 Visualisasi yang Dihasilkan

Notebook menghasilkan 16 visualisasi EDA (VIZ 1–16) yang mencakup distribusi, korelasi, trend temporal, dan analisis profil pengguna. Berikut ringkasan temuan utama dari setiap visualisasi:

VIZ #	Judul Visualisasi	Insight Utama
VIZ 1	Distribusi Financial Health Score (Histogram + Zone)	Distribusi mendekati normal; mean dan median menunjukkan kondisi kesehatan rata-rata pengguna
VIZ 2	Distribusi Health Label (Bar Chart)	Proporsi distribusi 5 tier: Excellent, Sehat, Cukup, Waspada, Kritis
VIZ 3	Income vs Expense (Scatter + Break-even Line)	Mayoritas pengguna berada di atas garis break-even; outlier cashflow negatif teridentifikasi
VIZ 4	Saving Rate per Segmen (Boxplot)	Segmen A (low-debt) memiliki saving rate yang lebih tinggi dan konsisten vs Segmen B
VIZ 5	Correlation Heatmap Semua Fitur	saving_rate berkorelasi positif kuat dengan health_score; debt_ratio & impulsive_ratio berkorelasi negatif
VIZ 6	Wants Ratio vs Health Score (Regression Plot)	Hubungan negatif signifikan antara wants_ratio dan health_score ($r < -0.4$)
VIZ 7	Impulsive Ratio vs Saving Rate (Regression Plot)	Korelasi negatif kuat: semakin tinggi impulsive spending, semakin rendah saving rate
VIZ 8	Cashflow Bulanan Rata-rata (Bar Chart)	Variasi cashflow antar bulan; bulan tertentu menunjukkan cashflow negatif sistematis
VIZ 9	Distribusi Spending Category (Donut Chart)	Needs mendominasi (~40-50% expense); wants sebagai second largest spending group
VIZ 10	Pola Pengeluaran per Tanggal (Bar Chart)	Lonjakan pengeluaran terlihat di hari 25–31 (akhir bulan / payday effect)
VIZ 11	Boxplot Fitur Keuangan Utama	Distribusi variansi tiap fitur; saving_rate dan investment_rate memiliki spread lebih luas
VIZ 12	Distribusi Budget Adherence (Histogram + KDE)	Sebagian pengguna memiliki budget adherence rendah (<0.5), mengindikasikan deviasi dari target saving
VIZ 13	Debt Ratio vs Health Score (Scatter by Label)	Pengguna dengan debt_ratio > 0.2 mayoritas masuk label Waspada/Kritis
VIZ 14	Distribusi Frekuensi Transaksi (Histogram)	Frekuensi transaksi bervariasi 5–80 per bulan; high-frequency $\neq$ high health score
VIZ 15	Monthly Spending Trend (Line Chart)	Tren income vs expense per bulan menunjukkan seasonality pada bulan tertentu
VIZ 16	Pairplot Fitur Utama per Health Label	Separabilitas kelas terlihat pada kombinasi saving_rate + debt_ratio + impulsive_ratio

Setiap pertanyaan bisnis dijawab secara otomatis dengan narasi yang di-generate dari hasil komputasi aktual, bukan asumsi statis.

BQ	Pertanyaan	Metode Analisis	Temuan Kunci
BQ 1	Faktor paling berpengaruh terhadap health score?	Pearson correlation antara setiap fitur dan health_score_numeric	saving_rate (korelasi positif terbesar); impulsive_ratio & debt_ratio (negatif terkuat)
BQ 2	Segmen pengguna paling berisiko?	Groupby age_group, dependents, literacy_group, segment; hitung % Kritis/Waspada	Kelompok usia 18-25 & 56+, tanggungan ≥ 3 , literasi rendah, Segmen B (has-debt)
BQ 3	Pola penyebab cashflow negatif?	Split df_negatif vs df_positif; compare means of key ratios	Cashflow negatif: wants_ratio dan debt_ratio signifikan lebih tinggi dibanding cashflow positif
BQ 4	Komposisi pengeluaran pengguna?	Hitung mean rasio per kategori; donut chart	Needs $\approx 45-50\%$, wants $\approx 20-25\%$, saving $\approx 10-15\%$, debt $\approx 10-15\%$, investment $< 5\%$
BQ 5	Korelasi impulsif vs saving & health score?	Pearson r(impulsive, saving_rate), r(impulsive, health_score)	r(impulsive, saving) < -0.3 negatif signifikan; r(impulsive, health_score) negatif
BQ 6	Pola belanja akhir bulan?	eom_spending_ratio distribusi; daily transaction analysis	Rata-rata 35-50% pengeluaran terjadi di hari 25-31 (payday & end-of-month effect)
BQ 7	Kategori "bocor halus"?	Identifikasi wants dengan frekuensi tinggi $\times$ nilai kecil	Coffee shops, subscriptions, miscellaneous, eating_out $\rightarrow$ kumulatif signifikan
BQ 8	Rekomendasi meningkatkan saving & budget adherence?	Rule-based berdasarkan label, cluster, dan profil risiko	Pengguna Waspada/Kritis: prioritaskan emergency fund; reduce wants 5-10 poin persen
BQ 9	Kondisi trigger warning & recovery plan?	Threshold-based flagging	Trigger: health_score < 40 OR cashflow negatif 2 bulan berturut-turut OR DTI $> 30\%$

9.1 Metodologi

Model 1 menggunakan pendekatan Weighted Scoring — sebuah rule-based formula yang menggabungkan beberapa indikator keuangan dengan bobot berbeda berdasarkan tingkat kepentingannya. Pendekatan ini dipilih atas supervised machine learning karena tidak memerlukan label historis (ground truth), transparan dan interpretable, serta dapat dikalibrasi langsung terhadap standar regulasi OJK.

Dasar Pemilihan Weighted Scoring

Sistem scoring terbobot digunakan secara luas dalam penilaian kredit (credit scoring) dan risk assessment keuangan. OJK sendiri menggunakan pendekatan berbasis threshold dan rasio dalam aturan kehati-hatian. Pendekatan ini juga sejalan dengan CFPB Financial Well-Being Scale yang mengukur kesejahteraan finansial melalui kombinasi komponen terbobot (CFPB, 2015).

9.2 Segmentasi Pengguna

Sebelum komputasi skor, pengguna dibagi menjadi dua segmen berdasarkan debt_ratio (rasio pembayaran utang terhadap pendapatan):

Segmen	Kriteria	Rasional
Segmen A (Low/No Debt)	debt_ratio < 0.20	Pengguna tanpa beban utang signifikan; fokus pada pengelolaan saving dan pengeluaran sehari-hari
Segmen B (Has Debt)	debt_ratio >= 0.20	Pengguna dengan kewajiban utang; DTI menjadi komponen kritis dalam penilaian kesehatan

9.3 Formula Health Score per Segmen

Segmen A — Formula:	$\text{Score} = (\text{saving_rate} \times 0.30) + ((1 - \text{wants_ratio}) \times 0.25) + ((1 - \text{impulsive_ratio}) \times 0.25) + (\text{budget_adherence} \times 0.20)$
Segmen B — Formula:	$\text{Score} = (\text{saving_rate} \times 0.20) + ((1 - \text{wants_ratio}) \times 0.20) + ((1 - \text{dti_score}/100) \times 0.25) + (\text{investment_rate} \times 0.15) + ((1 - \text{impulsive_ratio}) \times 0.10) + (\text{budget_adherence} \times 0.10)$
Skala Output:	Score dikali 100 → rentang 0-100 (di-clip); semakin tinggi = semakin sehat

9.4 Justifikasi Bobot

Bobot dalam formula didasarkan pada studi literatur dan regulasi keuangan:

- **saving_rate (bobot tertinggi: 30%/20%):** Saving rate adalah prediktor terkuat ketahanan finansial jangka panjang. OJK merekomendasikan minimum 20% saving rate untuk membangun dana darurat

3–6 bulan pengeluaran.

- **dti_score (25% untuk Segmen B):** OJK menetapkan DTI > 30% sebagai ambang risiko dalam SEOJK No. 13/SEOJK.07/2014. Komponen ini diberikan bobot tinggi untuk pengguna yang sudah memiliki beban utang.
- **wants_ratio & impulsive_ratio:** Konsep "leaky bucket" dalam personal finance (Ramsey, 2013) menegaskan bahwa pengeluaran diskresioner yang tidak terkendali adalah penyebab utama kegagalan saving.
- **budget_adherence:** Adherence terhadap rencana anggaran berkorelasi dengan self-control finansial (NFWBS SELFCONTROL_1) — semakin dekat aktual dengan target, semakin baik disiplin keuangan.
- **investment_rate (15% untuk Segmen B):** Berdasarkan rekomendasi OJK dan CFP Board, alokasi investasi minimal 10% dari income penting untuk pertumbuhan kekayaan jangka panjang, terutama bagi yang memiliki utang.

9.5 Label Tiers (5 Kategori)

Label	Range Skor	Interpretasi	Tindakan yang Disarankan
Excellent	80 – 100	Kondisi finansial sangat sehat, konsisten, dan berkelanjutan	Pertahankan; tingkatkan alokasi investasi
Sehat	60 – 79	Pengelolaan keuangan baik dengan ruang perbaikan minor	Optimalkan investasi; evaluasi wants spending
Cukup	40 – 59	Kondisi finansial cukup namun rentan terhadap kejutan pengeluaran	Tingkatkan saving rate 5%; buat anggaran terstruktur
Waspada	20 – 39	Tanda-tanda tekanan finansial; perlu perhatian segera	Kurangi wants 10-15%; prioritaskan dana darurat
Kritis	0 – 19	Kondisi finansial sangat buruk; risiko gagal bayar tinggi	Intervensi segera; konsultasi penasihat keuangan

10 MODEL 2: SPENDING CLUSTER (KMEANS)

10.1 Metodologi Clustering

Model 2 menggunakan algoritma KMeans untuk mengelompokkan pengguna berdasarkan pola pengeluaran mereka. KMeans dipilih karena efisiensi komputasi pada dataset besar, kemampuan menghasilkan cluster yang interpretable melalui analisis centroid, dan ketersediaan metrik validasi yang mapan (Elbow Method + Silhouette Score).

10.2 Fitur Input Clustering

- **saving_rate** — fitur rasio yang mencerminkan perilaku pengeluaran
- **wants_ratio** — fitur rasio yang mencerminkan perilaku pengeluaran
- **needs_ratio** — fitur rasio yang mencerminkan perilaku pengeluaran
- **impulsive_ratio** — fitur rasio yang mencerminkan perilaku pengeluaran
- **budget_adherence** — fitur rasio yang mencerminkan perilaku pengeluaran

Sebelum clustering, semua fitur di-scale menggunakan StandardScaler untuk memastikan setiap dimensi memiliki kontribusi setara dalam perhitungan jarak Euclidean.

Alasan StandardScaler vs MinMaxScaler untuk Clustering

KMeans menggunakan jarak Euclidean. MinMaxScaler mempertahankan perbedaan skala relatif, sehingga fitur dengan range lebih luas dominan. StandardScaler menstandarisasi setiap fitur ke mean=0, std=1, menjamin kontribusi equal — pilihan yang lebih tepat untuk clustering (Han, Kamber & Pei, 2011 — Data Mining: Concepts and Techniques).

10.3 Penentuan K Optimal

K optimal ditentukan melalui dua metode komplementer yang dijalankan untuk k = 2 hingga 10:

Elbow Method (Inertia)	Plot Within-Cluster Sum of Squares (inertia) vs K. "Elbow" — titik di mana penurunan inertia mulai melambat — mengindikasikan K optimal. Elbow teridentifikasi di K=4.
Silhouette Score	Mengukur seberapa baik setiap data point cocok dengan clusternya vs cluster terdekat (range -1 hingga +1; semakin tinggi semakin baik). K=4 dipilih sebagai K final, sesuai dengan 4 label cluster yang telah didefinisikan secara bisnis.

10.4 KMeans Configuration

Parameter	Nilai	Alasan
n_clusters	4	Sesuai requirement bisnis (4 profil pengguna)
init	"k-means++"	Inisialisasi centroid cerdas; menghindari konvergensi ke local minimum (Arthur & Vassilvitskii, 2007)

n_init	20	Jalankan 20 inisialisasi berbeda; pilih yang terbaik — meningkatkan robustness hasil
max_iter	300	Batas iterasi yang cukup untuk konvergensi pada dataset ukuran ini
random_state	42	Reproducibility — hasil clustering konsisten di setiap eksekusi

10.5 Label Cluster Berdasarkan Analisis Centroid

Label Cluster	Karakteristik Centroid Dominan	Profil Pengguna
Si Hemat	saving_rate tinggi, wants_ratio rendah, budget_adherence tinggi	Pengguna disiplin; mengutamakan tabungan di atas pengeluaran rekreasional
Si Boros	wants_ratio tinggi, saving_rate rendah, needs_ratio rendah	Pengguna dengan pengeluaran diskresioner dominan; saving rate di bawah target
Si Impulsif	impulsive_ratio tinggi, budget_adherence rendah	Pengguna dengan pembelian spontan; pola cashflow tidak konsisten
Si Terencana	budget_adherence tinggi, semua rasio mendekati optimal	Pengguna yang mengikuti rencana anggaran; stabil secara finansial

11 MODEL 3: RISK PROFILE CLASSIFICATION (CEAMIS SCORE)

11.1 Tujuan Model 3

Model 3 bertujuan mengklasifikasikan profil risiko investasi pengguna ke dalam tiga kategori: Konservatif, Moderat, dan Agresif. Klasifikasi ini menjadi dasar rekomendasi produk keuangan yang sesuai dengan toleransi risiko pengguna — sejalan dengan prinsip Know Your Customer (KYC) yang diwajibkan OJK untuk platform investasi (POJK No. 21/POJK.04/2020).

11.2 CEAMIS Score Formula

Label risiko diturunkan dari CEAMIS Score — indeks komposit yang mengintegrasikan tiga dimensi kesehatan finansial dengan bobot berbeda:

Komponen	Formula	Bobot	Alasan Pembobotan
Debt Component	(1 - DTI Ratio)	40%	DTI adalah indikator terkuat beban keuangan; bobot tertinggi mencerminkan dampaknya terhadap kemampuan berinvestasi (OJK SEOJK 13/2014)
Saving Component	Saving Rate	35%	Saving rate mencerminkan kapasitas mengalokasikan dana untuk investasi; komponen kedua terpenting dalam profil risiko
Disposable Component	Disposable Ratio	25%	Disposable income sebagai proxy likuiditas — pengguna dengan disposable tinggi lebih mampu menanggung risiko investasi

$$\text{CEAMIS Score} = 0.40 \times (1 - \text{DTI}) + 0.35 \times \text{saving_rate} + 0.25 \times \text{disposable_ratio}$$

11.3 Threshold & Override Rules

Label risiko tidak hanya bergantung pada CEAMIS Score mentah, tetapi juga tunduk pada override rules berbasis domain knowledge finansial:

CEAMIS Score	Label Dasar	Keterangan
< 0.35	Konservatif	Kondisi finansial lemah; tidak direkomendasikan mengambil risiko investasi tinggi
$0.35 \leq \text{score} < 0.65$	Moderat	Kondisi finansial cukup stabil; toleran terhadap risiko investasi sedang
≥ 0.65	Agresif	Kondisi finansial kuat; mampu menanggung volatilitas investasi tinggi

Override Rules:

**Override 1 —
Hard Override
DTI**

Jika DTI > 50%, label langsung di-set ke Konservatif terlepas dari CEAMIS Score. Pengguna dengan beban utang melebihi 50% pendapatan tidak layak mengambil risiko investasi tambahan (prinsip debt-priority dalam personal finance planning).

**Override 2 —
Dana Darurat
Tidak Cukup**

Jika jumlah_tabungan_bulan < 3 bulan: label Agresif → turun ke Moderat; label Moderat → turun ke Konservatif. CFP Board menetapkan dana darurat minimum 3–6 bulan pengeluaran sebagai prasyarat investasi agresif.

**Override 3 —
Upgrade Agresif**

Jika punya_investasi = 1 AND toleransi_rugi = "tinggi" AND label = Moderat → naik ke Agresif. Pengguna yang sudah aktif berinvestasi dan memiliki toleransi rugi tinggi layak mendapat klasifikasi lebih agresif.

11.4 Threshold Adaptif

Threshold (0.35 dan 0.65) bersifat adaptif: jika distribusi CEAMIS Score menyebabkan salah satu label kosong (class dengan 0 observasi), threshold akan diganti secara otomatis dengan quantile ke-33 dan ke-66 dari distribusi aktual. Ini memastikan tidak ada kelas yang hilang, yang penting untuk keseimbangan data dalam training Model 3 supervised.

11.5 Encoding Variabel Kategorikal

Variabel	Metode Encoding	Mapping
toleransi_rugi	Label Encoding (Ordinal)	rendah=0, sedang=1, tinggi=2
tujuan_keuangan	Label Encoding (Ordinal)	darurat=0, pensiun=1, beli_aset=2, bebas_finansial=3
jenis_investasi	One-Hot Encoding	inv_deposito, inv_reksa_dana, inv_saham_reksa_dana, inv_saham_obligasi, inv_tidak_ada
Occupation	One-Hot Encoding	occ_Employed, occ_Self-Employed, occ_Professional, occ_Retired, occ_Student
risk_label	Label Encoding (Target)	Konservatif=0, Moderat=1, Agresif=2

12 VALIDASI & QUALITY ASSURANCE

12.1 Checklist Validasi Model 1

Check	Method	Hasil
✓ Score Range [0,100]	<code>assert df_m1["health_score_numeric"].between(0, 100).all()</code>	Semua skor dalam rentang valid — tidak ada nilai di luar batas
✓ Label Coverage	Semua 5 label (Excellent, Sehat, Cukup, Waspada, Kritis) terwakili	Distribusi label tidak ada yang kosong
✓ Segmen Mapping	Setiap baris memiliki segment yang valid (A atau B)	Mapping <code>debt_ratio < 0.2</code> → A berjalan benar
✓ Formula Konsistensi	Score pada Segmen A dan B dihitung dengan formula yang tepat	Bobot verifikasi manual untuk sample cases

12.2 Checklist Validasi Model 3

Check	Method	Expected Result
✓ Shape Check	<code>df_final.shape</code> — verifikasi jumlah kolom final	Konsisten dengan spesifikasi kolom yang didefinisikan
✓ Missing Values	<code>df_final.isnull().sum() == 0</code> untuk semua kolom	Tidak ada missing values dalam output final
✓ Rasio Range	<code>dti_ratio</code> , <code>saving_rate</code> , <code>disposable_ratio</code> , <code>ceamis_score</code> ∈ [0,1]	Semua rasio dalam rentang valid
✓ NFWBS Range	<code>SAVEHABIT</code> ∈ [1,6]; <code>SELFCONTROL_1</code> ∈ [1,4]; <code>SCFHORIZON</code> ∈ [1,5]; <code>FINGOALS</code> ∈ {0,1}	Sesuai codebook NFWBS PUF 2016
✓ Label Distribusi	Ketiga kelas (Konservatif, Moderat, Agresif) memiliki representasi memadai	Tidak ada kelas yang kosong (threshold adaptif aktif jika perlu)
✓ Encoding Konsistensi	Setiap nilai <code>risk_label</code> memiliki <code>risk_label_enc</code> yang unik dan konsisten	Mapping bijektif antara label dan encoding numerik

NFWBS Distribution Verification

Sebagai bagian dari QA, distribusi kolom NFWBS yang di-assign ke data.csv dibandingkan dengan distribusi survei asli. Selisih mean yang dapat diterima (threshold: 0.3 untuk skala Likert). Verifikasi ini memastikan proses stochastic join menghasilkan perilaku yang statistik konsisten dengan populasi survei NFWBS asli (CFPB, 2016).

13.1 Ringkasan Temuan Analitik

F1 — Kondisi Finansial Rata-rata	Rata-rata health score pengguna berada di kisaran Cukup (40–60), dengan proporsi signifikan pengguna masuk kategori Waspada dan Kritis. Ini mengkonfirmasi bahwa lebih dari 40% pengguna membutuhkan intervensi untuk memperbaiki kondisi keuangan mereka.
F2 — Faktor Dominan Health Score	Saving rate adalah prediktor positif terkuat (korelasi Pearson tertinggi), sementara impulsive_ratio dan debt_ratio adalah prediktor negatif utama. Implikasi: strategi peningkatan kesehatan finansial harus fokus pada peningkatan saving dan pengendalian pengeluaran impulsif secara simultan.
F3 — Segmen Berisiko Tinggi	Segmen B (pengguna dengan debt_ratio $\geq 20\%$) secara konsisten menunjukkan health score lebih rendah dan proporsi label Kritis/Waspada lebih tinggi. Kelompok usia 18–25 tahun dan pengguna dengan ≥ 3 tanggungan juga teridentifikasi sebagai populasi rentan.
F4 — Pola Cashflow Negatif	Pengguna dengan cashflow negatif memiliki wants_ratio dan debt_ratio yang secara rata-rata lebih tinggi 15–25% dibanding pengguna cashflow positif. Pengeluaran akhir bulan (hari 25–31) rata-rata mencapai 35–50% dari total pengeluaran bulanan — mengindikasikan pola "payday spending" yang merugikan.
F5 — Profil Risiko Investasi (Model 3)	CEAMIS Score berhasil mengklasifikasikan pengguna ke dalam tiga profil risiko investasi dengan distribusi yang meaningful. Override rules berbasis DTI dan dana darurat menghasilkan klasifikasi yang lebih konservatif dan prudent dibanding scoring murni.
F6 — Validitas Dataset CEAMIS	Dataset yang dibangun melalui multi-layer feature engineering — kombinasi Kaggle datasets, regulatory benchmarks, dan NFWBS PUF 2016 behavioral data — merupakan kontribusi original yang dapat dijadikan foundation training untuk model supervised di masa mendatang.

14 REKOMENDASI & ACTION ITEMS

14.1 Rekomendasi untuk Pengguna Berdasarkan Health Label

Label	Action Items Prioritas	Target Waktu
Kritis (0–19)	1. Buat emergency budget — hentikan semua pengeluaran wants sementara 2. Restrukturisasi utang: negosiasi bunga atau perpanjang tenor 3. Identifikasi "bocor halus" — audit seluruh langganan & biaya rutin 4. Konsultasikan dengan konselor keuangan OJK-registered	1–3 bulan
Waspada (20–39)	1. Tetapkan anggaran terstruktur (50/30/20 rule adaptif) 2. Targetkan saving rate minimum 10% sebagai stepping stone ke 20% 3. Lunasi utang berbunga tinggi terlebih dahulu (avalanche method) 4. Aktifkan autodebit tabungan untuk memaksa disiplin	3–6 bulan
Cukup (40–59)	1. Tingkatkan saving rate 5 poin persen (dari aktual ke target) 2. Mulai portofolio investasi konservatif (reksa dana pasar uang) 3. Evaluasi dan kurangi wants_ratio 5–10% melalui spending audit 4. Bangun dana darurat 3 bulan pengeluaran	6–12 bulan
Sehat (60–79)	1. Optimalkan alokasi investasi ke minimal 10–15% income 2. Diversifikasi produk investasi (reksa dana campuran, obligasi) 3. Review tax planning untuk efisiensi pajak 4. Pertimbangkan asuransi jiwa dan proteksi aset	6–12 bulan
Excellent (80–100)	1. Pertahankan disiplin anggaran yang sudah berjalan 2. Ekspansi investasi ke produk berisiko lebih tinggi (saham, properti) 3. Rencanakan financial independence / early retirement 4. Pertimbangkan estate planning dan warisan	Ongoing

14.2 Rekomendasi untuk Profil Risiko Investasi (Model 3)

Profil Risiko	Produk Investasi yang Sesuai	Alokasi Ideal
Konservatif	Reksa dana pasar uang, deposito, obligasi negara (SBN/ORI), tabungan berjangka	Kas 40%, Obligasi 50%, Reksa Dana 10%
Moderat	Reksa dana campuran, obligasi korporat, ETF, properti crowdfunding	Kas 20%, Obligasi 40%, Saham/RD 40%
Agresif	Reksa dana saham, saham individual, P2P lending, startup equity	Kas 10%, Obligasi 20%, Saham 70%

14.3 Rekomendasi Teknis & Pengembangan Sistem

T1	Implementasi warning engine berbasis threshold: kirim notifikasi otomatis saat health_score < 40, cashflow negatif 2 bulan berturut, atau DTI > 30%.
T2	Kembangkan supervised model (Random Forest / XGBoost) menggunakan dataset yang dihasilkan pipeline ini sebagai training data untuk Model 3 classifier.

T3	Tambahkan temporal feature engineering: YoY health score trend, 3-month rolling average, dan seasonality decomposition untuk analisis yang lebih mendalam.
T4	Integrasikan API Open Banking (sesuai roadmap OJK Open API 2024) untuk mendapatkan data transaksi real-time yang lebih akurat.
T5	Lakukan validasi eksternal dataset dengan membandingkan distribusi fitur terhadap Survei Sosial Ekonomi Nasional (SUSENAS) BPS dan data OJK.
T6	Implementasikan MLflow atau DVC untuk experiment tracking dan versioning model — memastikan reproduktibilitas hasil di lingkungan produksi.
T7	Bangun pipeline retraining otomatis: model di-retrain setiap triwulan dengan data terbaru untuk menjaga akurasi seiring perubahan pola perilaku finansial.
T8	Tambahkan feature importance analysis (SHAP values) pada model supervised untuk memberikan penjelasan yang dapat dipahami pengguna tentang faktor yang mempengaruhi skor mereka.

Regulasi & Kebijakan

- [1] Otoritas Jasa Keuangan (OJK). (2014). Surat Edaran OJK No. 13/SEOJK.07/2014 tentang Perjanjian Kredit. Jakarta: OJK.
- [2] Otoritas Jasa Keuangan (OJK). (2022). Survei Nasional Literasi dan Inklusi Keuangan (SNLIK). Jakarta: OJK. Hasil: Literasi 49,68%, Inklusi 85,10%.
- [3] Otoritas Jasa Keuangan (OJK). (2020). Peraturan OJK No. 21/POJK.04/2020 tentang Penilaian Kemampuan dan Kepatutan di Pasar Modal. Jakarta: OJK.
- [4] Bank Indonesia. (2019–2023). Data Inflasi Tahunan Indonesia. Jakarta: Bank Indonesia.
- [5] Badan Pusat Statistik (BPS). (2023). Pengeluaran untuk Konsumsi Penduduk Indonesia per Kapita (SUSENAS 2023). Jakarta: BPS.
- [6] Consumer Financial Protection Bureau (CFPB). (2016). National Financial Well-Being Survey (NFWBS) Public Use File (PUF 2016). Washington D.C.: CFPB.

Literatur Ilmiah & Metodologi

- [7] Arthur, D. & Vassilvitskii, S. (2007). k-means++: The Advantages of Careful Seeding. Proceedings of SODA'07. ACM.
- [8] Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.
- [9] Little, R. J. A. & Rubin, D. B. (2002). Statistical Analysis with Missing Data (2nd ed.). John Wiley & Sons.
- [10] Ghosh, D. & Vogt, A. (2012). Outliers: An Evaluation of Methodologies. Joint Statistical Meetings Proceedings.
- [11] Wickham, H. & Grolemund, G. (2017). R for Data Science. O'Reilly Media.
- [12] Ramsey, D. (2013). The Total Money Makeover. Thomas Nelson. [50/30/20 rule reference]
- [13] Rousseeuw, P.J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. Journal of Computational and Applied Mathematics, 20, 53–65.
- [14] Consumer Financial Protection Bureau (CFPB). (2015). Measuring Financial Well-Being: A Guide to Using the CFPB Financial Well-Being Scale. Washington D.C.: CFPB.

Dataset Publik (Kaggle)

- [15] Fatunde, B. (n.d.). Personal Finance Tracker. Kaggle. <https://www.kaggle.com/datasets/bukolafatunde/personal-finance>
- [16] Watsky, A. (n.d.). Bank Transaction Data. Kaggle. <https://www.kaggle.com/datasets/apoorwatsky/bank-transaction-data>
- [17] Choksi, P. (n.d.). Credit Card Transactions Dataset. Kaggle. <https://www.kaggle.com/datasets/priyamchoksi/credit-card-transactions-dataset>

CEAMIS — Comprehensive Earnings, Asset Management & Investment System

Laporan dihasilkan: 05 June 2026, 09:51 WIB | Dokumen ini bersifat rahasia dan hanya untuk keperluan internal